

MLP architektura

Srpen 2025

V tomto textu je rozebrána architektura MLP (Multi-Layer Perceptron) neuronové sítě.

1 Neuron a architektura

Na obrázku níže je uveden příklad architektury neuronové sítě. Síť má vstupní vrstvu se 2 neurony, dvě skryté vrstvy se 3 a 2 neurony a výstupní vrstvu se 2 neurony.

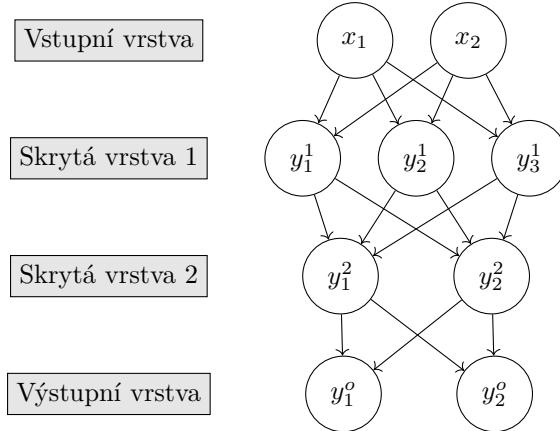


Figure 1: Příklad MLP architektury neuronové sítě.

Vstupní vrstva obsahuje vektor vytvořený z tréninkových dat:

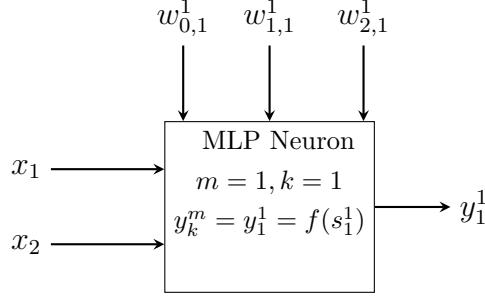
$$\mathbf{X} = (x_0, x_1, x_2, \dots, x_n)^T \quad (1)$$

kde hodnoty x_i jsou normalizovány na interval $< 0, 1 >$.

Hodnoty neuronů ve vstupní vrstvě jsou:

$$\mathbf{Y}^0 = \mathbf{X} \quad (2)$$

Ve skrytých vrstvách mají neurony hodnoty označené jako \mathbf{Y}^k . Každý neuron má přiřazené váhy w_i a bias w_0 . Následuje ilustrace neuronu.



$w_{j,k}^m$ značí váhu spojení od neuronu j z vrstvy $m - 1$ k neuronu k z vrstvy m . Neurony jsou indexovány od 1 a $w_{0,k}^m$ značí bias neuronu k ve vrstvě m . s_k^m je vnitřní potenciál neuronu k ve vrstvě m .

2 Forward propagace

Vnitřní potenciál neuronu se určí pomocí aktivační funkce $f(s)$, kde platí

$$s_k^m = \sum_j w_{jk}^m y_j^{m-1} \quad (3)$$

kde j je index vstupů z předchozí vrstvy $m - 1$ a k je index neuronu ve vrstvě m . Hodnotu y_0^{m-1} od neexistujícího neuronu 0 lze definovat jako 1 a tím rovnice platí i pro biasy.

Aktivační funkce $f(s)$ může být definována různým způsobem, například lze použít RELU funkci

$$y_k^m = f(s_k^m) = \max(0, s_k^m) \quad (4)$$

RELU funkce umožňuje vznik hodnot vyšších než 1. Pokud je vyžadováno, aby výstupy y_j nabývaly pouze hodnot od 0 do 1, lze použít jinou aktivační funkci pro výstupní vrstvu.

3 Handling výstupních hodnot

Při aplikaci na rozpoznávání číslic od 0 do 9 je možné použít převod číslice na 10 skutečných výstupů y_k^{skut} následujícím způsobem:

$\mathbf{Y}^{\text{skut}}(\text{číslice})$	y_0^{skut}	y_1^{skut}	y_2^{skut}	y_3^{skut}	y_4^{skut}	y_5^{skut}	y_6^{skut}	y_7^{skut}	y_8^{skut}	y_9^{skut}
$\mathbf{Y}^{\text{skut}}(0)$	1	0	0	0	0	0	0	0	0	0
$\mathbf{Y}^{\text{skut}}(1)$	0	1	0	0	0	0	0	0	0	0
$\mathbf{Y}^{\text{skut}}(2)$	0	0	1	0	0	0	0	0	0	0
$\mathbf{Y}^{\text{skut}}(3)$	0	0	0	1	0	0	0	0	0	0
$\mathbf{Y}^{\text{skut}}(4)$	0	0	0	0	1	0	0	0	0	0
$\mathbf{Y}^{\text{skut}}(5)$	0	0	0	0	0	1	0	0	0	0
$\mathbf{Y}^{\text{skut}}(6)$	0	0	0	0	0	0	1	0	0	0
$\mathbf{Y}^{\text{skut}}(7)$	0	0	0	0	0	0	0	1	0	0
$\mathbf{Y}^{\text{skut}}(8)$	0	0	0	0	0	0	0	0	1	0
$\mathbf{Y}^{\text{skut}}(9)$	0	0	0	0	0	0	0	0	0	1

Například číslici 3 tedy odpovídá vektor skutečných výstupů:

$$\mathbf{Y}^{\text{skut}}(3) = (0, 0, 0, 1, 0, 0, 0, 0, 0, 0)^T \quad (5)$$

Opačný převod 10 výstupů y_i na číslici lze uskutečnit hledáním maximálního výstupu:

$$\text{číslice} = \text{argmax}(\mathbf{Y}) \quad (6)$$

4 Zpětná propagace

Při zpětné propagaci dochází k opačnému průchodu přes síť a k úpravě vah na základě chyby, které se síť při učení dopustila. Chyba se šíří zpět pomocí funkce energie, označené jako E . Pro ukázkou použijeme funkci střední kvadratické chyby (MSE):

$$E = \sum_k \frac{1}{2} (y_k - d_k)^2 \quad (7)$$

kde $d_k = y_k^{\text{skut}}$ (desired).

Derivace energie vzhledem k vahám v libovolné vrstvě je (řetězové pravidlo):

$$\frac{\partial E}{\partial w_{jk}} = \frac{\partial E}{\partial s_k} \frac{\partial s_k}{\partial w_{jk}} \quad (8)$$

Ve výstupní vrstvě lze dále rozepsat:

$$\frac{\partial E}{\partial w_{jk}} = \frac{\partial E}{\partial y_k^o} \frac{\partial y_k^o}{\partial s_k^o} \frac{\partial s_k^o}{\partial w_{jk}} = \frac{\partial E}{\partial w_{jk}} = -(d_k^o - y_k^o) f'(s_k^o) y_j^{o-1} = \delta^o y_j^{o-1} \quad (9)$$

Úprava nastavení vah pro výstupní vrstvu směruje proti gradientu energie, tedy pro výstupní vrstvu platí

$$\Delta w_{jk}^o = \eta (d_k^o - y_k^o) f'(s_k^o) y_j = \eta \delta_k^o y_j^{o-1} \quad (10)$$

kde η je učící rychlosť (learning rate). Bez odvození uvedeme, že pro úpravu vah v dalších vrstvách platí obecný vztah

$$\Delta w_{jk}^m = \eta \delta_k^m y_j^{m-1} \quad (11)$$

kde rekurzivně

$$\delta_k^m = \left(\sum_{l=0}^{N_{m+1}} \delta_l^{m+1} w_{kl}^{m+1} \right) f'(s_k^m) \quad (12)$$

a

$$\delta_k^o = (d_k^o - y_k^o) f'(s_k^o) \quad (13)$$